

# 시계열자료분석팀

5팀

장다연

심현구

윤세인

이동기

천예원

# INDEX

---

1. 시계열 자료 분석

2. 정상성

3. 정상화

4. 정상성 검정


# 1

## 시계열 자료 분석

## 시계열 자료란?

## 시계열 자료 (Time Series)

시간 순서에 따라 관측된 자료의 집합



$$\{X_t, t = 1, 2, 3, \dots\}$$

$t$  : 시점,  $t$ 의 종류에 따라 연속형, 이산형 자료로 분류됨.

## 시계열 자료의 특징

연관성

(dependency)

시간의 흐름이 반영되어  
관측치들 사이에 연관성이 존재함

결합분포

(joint distribution)

특정 시점  $X$   
전체 시점에서의 관측치 집합 모두 고려

## 시계열 자료의 특징



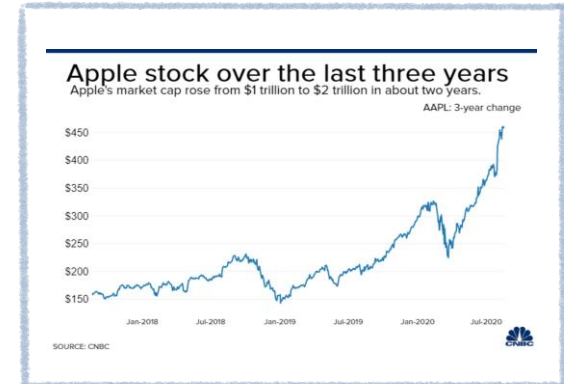
연관성 독립성 조건을 만족하지 않는 특징으로 인해  
(dependency) 일반적인 선형회귀 방법 사용 X (joint distribution)

데이터의 특성을 반영할 수 있는 특별한 분석법,  
시간의 흐름이 반영되어 특정 시점에서의 관측치 집합만을 고려 X  
관측치들 사이에 연관성이 존재함 시계열 분석 필요 전체 시점에서의 관측치 집합 모두 고려

## 시계열 자료 분석


## 추세 (trend)

시간에 따라 증감하는 변동  
특별한 충격이 없는 한 지속됨.



## 순환 변동 (cycle)

일정 주기를 가지는 변동  
주기가 규칙적이진 않음.



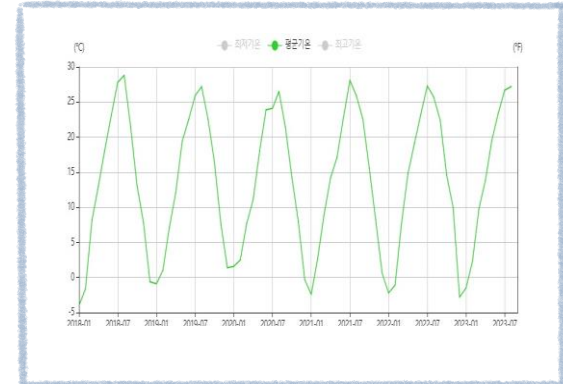
## 시계열 자료 분석

## 시계열 자료의 구성 요소

## 계절성 (seasonality)

규칙적인 주기를 가지는 변동  
주별, 월별, 계절별과 같이  
특정 시간 간격을 가짐

■ ■ ■ ■ ■ ■ ■

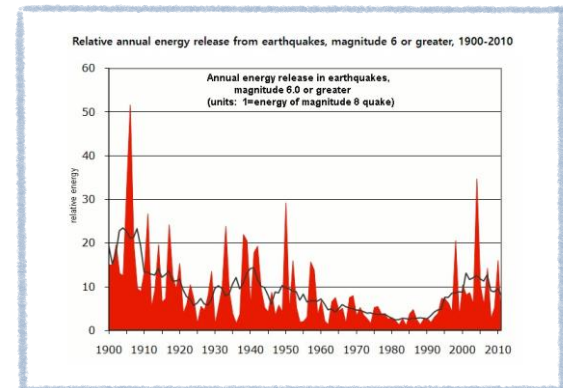


우연변동  
(Random fluctuation)

■ ■ ■ ■ ■ ■ ■

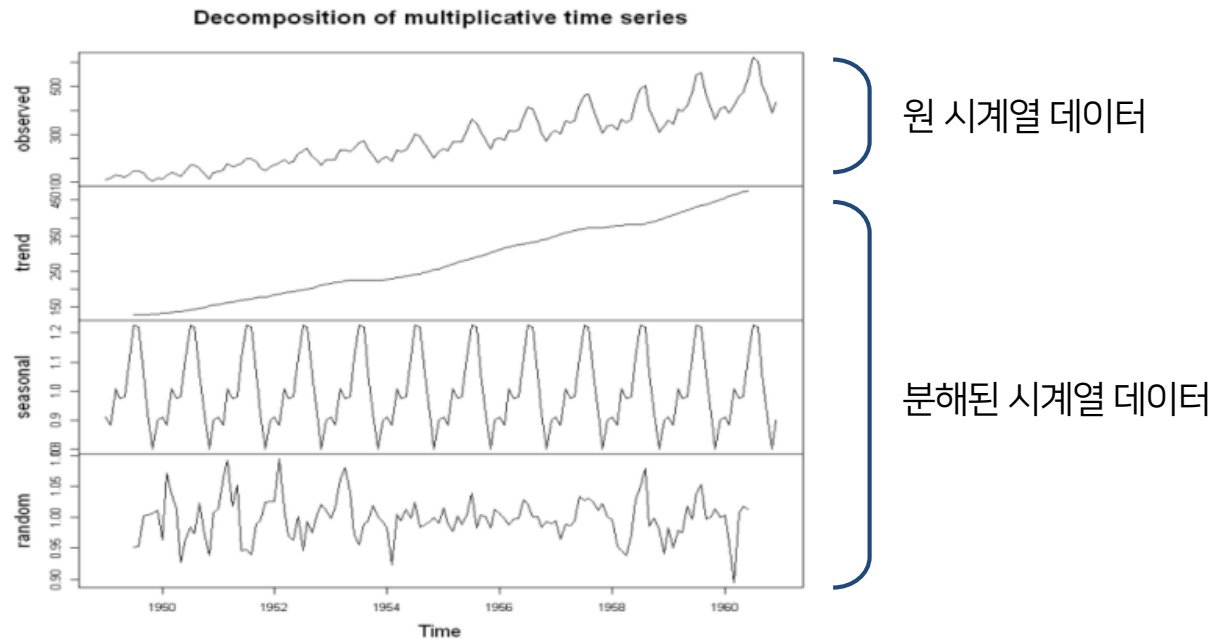
**무작위적임**

일정한 규칙성을 보이지 않음





## 시계열 분해



시계열 분석에서는 위 그림과 같이 4가지 구성요소를 분해

## 시계열 분해

## 시계열 분해 (Time Series Decomposition)

시계열 자료를 비정상 부분(non-stationary part)과  
정상 부분(stationary part)으로 분해하는 작업

추세( $m_t$ )와 계절성( $s_t$ )은 비정상 부분, 오차( $Y_t$ )는 정상 부분

## 덧셈 분해

$$X_t = m_t + s_t + Y_t$$

## 곱셈 분해

$$X_t = m_t * s_t * Y_t$$

데이터에 0이 포함되어 있는지 확인 必



추세와 계절성을 제거하여 오차를 이용해 예측 모델링 진행함.

## 시계열 분해



## 시계열 분해(Time Series Decomposition)

## 덧셈 분해 vs 곱셈 분해

시계열 자료를 **추세 성분**(trend part)과  
**계절 성분**(seasonal part)과  
**정상 부분**(stationary part)으로 분해하는 작업

덧셈 분해는 추세와 계절성을 별개의 구성 요소로 보지만, 정상 부분

곱셈 분해는 추세에 따라 계절성이 변화함을 가정함

클린업에서는 주로 덧셈 분해에 대해 다룰 예정임

덧셈 분해

$$X_t = m_t + s_t + Y_t$$

곱셈 분해

$$X_t = m_t * s_t * Y_t$$

추세와 계절성을 제거하여 오차를 이용해 예측 모델링 진행함.

2

정상성

## 정상성이란?

## 정상성 (Stationarity)

시계열 자료의 **확률적 성질이** 시점  $t$ 에 의존하지 않고 **시차 lag에만 의존**하는 특성

강정상성

(Strict Stationarity)

약정상성

(Weak Stationarity)



## 강정상성

강정상성 (Strict Stationarity)

$$(X_{t_1}, \dots, X_{t_n}) \stackrel{d}{=} (X_{t_1+h}, \dots, X_{t_n+h})$$



즉, 일정한 시차 간격을 가지는 관측치 집합들이  
**모두 같은 분포**를 따른다는 것!

⋮

이렇게 엄격한 조건을 만족하는 시계열 데이터는 많지 않음

## 강정상성

강정상성에 정규성(Gaussianity)를 가정한다면?

$$(X_{t_1}, \dots, X_{t_n}) \sim MVN(\mu, \Sigma)$$



평균 벡터인  $\mu$ 와 공분산 행렬  $\Sigma$ 만 추정해서 전체 분포를 구할 수 있음

1. 확률 변수의 기댓값은 상수

$$E[X_t] = m, \forall t \in \mathbb{Z}$$

2. 공분산은 시차에 의존

$$\begin{aligned} &Cov(X_r, X_s) \\ &= Cov(X_{r+h}, X_{s+h}), \forall r, s, h \in \mathbb{Z} \end{aligned}$$

## 강정상성

강정상성에 정규성(Gaussianity)를 가정한다면?

$$(X_{t_1}, \dots, X_{t_n}) \sim MVN(\mu, \Sigma)$$

정규성을 가정하여 시차에만 의존하던 분포를 공분산으로 완화하였지만,  
여전히 엄격한 가정이기 때문에 현실에서는 **약정상성**을 이용

평균 벡터인  $\mu$ 와 공분산 행렬  $\Sigma$ 만 추정해서 전체 분포를 구할 수 있음

1. 확률 변수의 기댓값은 상수

$$E[X_t] = m, \forall t \in \mathbb{Z}$$

2. 공분산은 시차에 의존

$$\begin{aligned} & Cov(X_r, X_s) \\ &= Cov(X_{r+h}, X_{s+h}), \forall r, s, h \in \mathbb{Z} \end{aligned}$$



## 약정상성

## 약정상성 조건

$$1) E[|X_t|]^2 < \infty, \quad \forall t \in \mathbb{Z}$$

2차 적률이 존재하고 시점  $t$ 에 관계없이 일정함.

$$2) E[|X_t|]^2 = m, \quad \forall t \in \mathbb{Z}$$

평균이 상수로 시점  $t$ 에 관계없이 일정함.

$$3) \gamma_X(r, s) = \gamma_X(r + h, s + h),$$

$$\forall r, s, h \in \mathbb{Z}, \quad (\gamma_X(r, s) := \text{Cov}(X_r, X_s))$$

공분산은 시차  $h$ 에 의존하며 시점  $t$ 와 무관함.

클린업에서 다루는 모든 시계열 자료는 약정상성을 만족하는 시계열임.


3

정상화

## 정상 시계열과 비정상 시계열

- ✓ 시계열 플랏(TS plot)을 통해 시각적으로 확인 가능

### 정상 시계열




특별한 추세나 계절성이 보이지 않으며, 평균과 분산 역시 일정함.

## 정상 시계열과 비정상 시계열

- ✓ 시계열 플랏(TS plot)을 통해 시각적으로 확인 가능


### 비정상 시계열



평균이 일정하지 않음



분산이 일정하지 않음



공분산이 시점에 의존함

## 정상 시계열과 비정상 시계열


- ✓ 시계열 플랏(TS plot)을 통해 시각적으로 확인 가능

### 비정상 시계열


비정상 시계열의 경우 바로 분석에 사용할 수 없으므로  
정상 시계열로의 변환인 **정상화 과정**이 필요함.



평균이 일정하지 않음



분산이 일정하지 않음



공분산이 일정하지 않음



## 정상화가 필요한 이유

### 독립성 조건의 붕괴

시계열 자료는 오차의 독립성 조건을 만족하지 않기 때문에  
오차의 독립성을 가정하는 다양한 통계분석기법을 활용할 수 없음



시계열의 분해와 정상화를 통해 상관관계가 존재하지 않는 오차만 남긴 후 모델링을 진행

### 안정적이고 정확한 예측

정상성을 만족하지 않는 데이터를 사용하면  
데이터를 설명하는 모델의 정확도가 시점에 따라 달라질 수 있음

## 경우에 따른 정상화

분산이 일정하지 않은 경우

분산이 시점에 의존하지 않고 일정하다는  
약정상성 조건에 위배되는 상황



분산 안정화 변환

- 로그 (log) 변환
- 루트 (square root) 변환
- Box-Cox 변환

평균이 일정하지 않은 경우

추세 또는 계절성이 존재하여  
비정상 부분을 제거해야 하는 상황



- 회귀 (Regression)
- 평활 (Smoothing)
- 차분 (Differencing)

## 경우에 따른 정상화

분산이 일정하지 않은 경우

분산이 시점에 의존하지 않고 일정하다는  
약정상성 조건에 위배되는 상황



분산 안정화 변환

- 로그 (log) 변환
- 루트 (square root) 변환
- Box-Cox 변환

## 분산 안정화 변환

Variance Stabilizing Transformation(VST)

로그 변환

$$f(X_t) = \log(X_t)$$

제곱근 변환

$$f(X_t) = \sqrt{X_t}$$

Box-Cox 변환

$$f_{\lambda}(X_t) = \begin{cases} \frac{X_t^{\lambda} - 1}{\lambda}, & X_t \geq 0, \lambda > 0 \\ \log X_t, & \lambda = 0 \end{cases}$$



## 경우에 따른 정상화

분산이 일정하지 않은 경우

분산이 시점에 의존하지 않고 일정하다는  
약정상성 조건에 위배되는 상황



- 로그 (log) 변환
- 루트 (square root) 변환
- Box-Cox 변환

분산 안정화 변환



평균이 일정하지 않은 경우

추세 또는 계절성이 존재하는  
비정상 부분을 제거해야 하는 상황



- 회귀 (Regression)
- 평활 (Smoothing)
- 차분 (Differencing)

## 평균이 일정하지 않은 경우의 정상화 - ① 회귀

a. 추세만 존재하는 경우 : Polynomial Regression

기본 가정: 시계열이 추세만 가진다

$$X_t = m_t + Y_t$$

$m_t$  : 추세,  $Y_t$  : 정상성을 만족하는 오차

STEP 1) 추세 성분을 시간에 대한 **선형회귀식**으로 나타냄

$$m_t = c_0 + c_1 t + c_2 t^2 + \cdots + c_p t^p$$

$m_t$  : 추세,  $t$  : 시간

## 평균이 일정하지 않은 경우의 정상화 - ① 회귀

a. 추세만 존재하는 경우 : Polynomial Regression

STEP 2) 선형회귀식의 계수를 **최소제곱법(OLS)**을 통해 추정

$$(\hat{c}_0, \dots, \hat{c}_p) = \underset{c}{\operatorname{argmin}} \sum_{t=1}^n (X_t - m_t)^2$$

STEP 3) 추정한 추세를 비정상 시계열 ( $X_t$ )에서 제거

$$X_t - \hat{m}_t \approx Y_t$$

## 평균이 일정하지 않은 경우의 정상화 - ① 회귀

### b. 계절성만 존재하는 경우 : Harmonic Regression



영감... 미안해요.. 다시는 안뽑기로 했는데...  
울어라, 지옥참마도!

할모닉 ㅎㅎ

기본 가정: 시계열이 주기가  $d$ 인 계절성만을 가진다

$$X_t = s_t + Y_t$$

$$E(Y_t) = 0, \quad s_{t-d} = s_t = s_{t+d}$$

Step 1) 계절 성분  $s_t$ 를 시간  $t$ 에 대한 회귀식으로 표현

$$s_t = a_0 + \sum_{j=1}^k (a_j \cos(\lambda_j t) + b_j \sin(\lambda_j t))$$

$s_t, \lambda_t$  : constant

## 평균이 일정하지 않은 경우의 정상화 - ① 회귀

b. 계절성만 존재하는 경우 : Harmonic Regression

STEP 2) 적절한  $\lambda_j$ 와  $k$  선택 후, OLS를 통해  $a_j$ 와  $b_j$  추정

$$s_t = a_0 + \sum_{j=1}^k (a_j \cos(\lambda_j t) + b_j \sin(\lambda_j t))$$

STEP 3) 추정한 계절성을 시계열에서 제거

$$X_t - \hat{s}_t \approx Y_t$$



평균이 일정하지 않은 경우의 정상화 - 회귀

b. 계절성만 존재하는 경우 : **적절한  $\lambda_j$  와  $k$ 의 선택**

STEP 2) 적절한  $\lambda_j$  와  $k$  선택 후, OLS를 통해  $a_j$  와  $b_j$  추정

$\lambda_j$  : 주기가  $2\pi$ 인 함수의 주기와 데이터의 주기를 맞춰 주기 위한 값

$$\hat{s}_t = a_0 + \sum_{j=1}^k (a_j \cos(\lambda_j t) + b_j \sin(\lambda_j t))$$

① 주기 반복 횟수  $f_1 = \left\lfloor \frac{n}{d} \right\rfloor \rightarrow f_j = j * f_1$

②  $\lambda_j = f_j * (2\pi/n)$

STEP 3) 추정한 계절성을 시계열에서 제거

$k$ : 주로 1~4 사이의 값을 사용

$$X_t - \hat{s}_t \approx Y_t$$

$n$ : 데이터 개수,  $d$ : 주기

## 평균이 일정하지 않은 경우의 정상화 - ① 회귀

b. 계절성만 존재하는 경우 : Harmonic Regression

STEP 2) 적절한  $\lambda_j$ 와  $k$  선택 후, OLS를 통해  $a_j$ 와  $b_j$  추정

$$s_t = a_0 + \sum_{j=1}^k (a_j \cos(\lambda_j t) + b_j \sin(\lambda_j t))$$

STEP 3) 추정한 계절성을 시계열에서 제거

$$X_t - \hat{s}_t \approx Y_t$$

## 평균이 일정하지 않은 경우의 정상화 - ① 회귀

c. 추세와 계절성 모두 존재하는 경우

Polynomial Regression과 Harmonic Regression을 차례대로 진행



남아 있는 추세가 보인다면 동일한 과정을 반복하여 제거



## 평균이 일정하지 않은 경우의 정상화 - ② 평활



회귀 방법은 전체 데이터를 한번에 처리  
따라서 국소적 변동이 존재하는 경우 부적합



### 평활법 (smoothing)

시계열 자료를 여러 구간으로 나눈 뒤  
구간의 평균들로 추세를 추정하는 방법

## 평균이 일정하지 않은 경우의 정상화 - ② 평활

### a. 추세만 존재하는 경우

#### 이동평균 평활법

일정 구간마다 평균을 계산해  
추세를 추정, 제거하는 방법

#### 지수 평활법

$t$  시점까지의 관측값을 이용해  
추세를 추정, 제거하는 방법

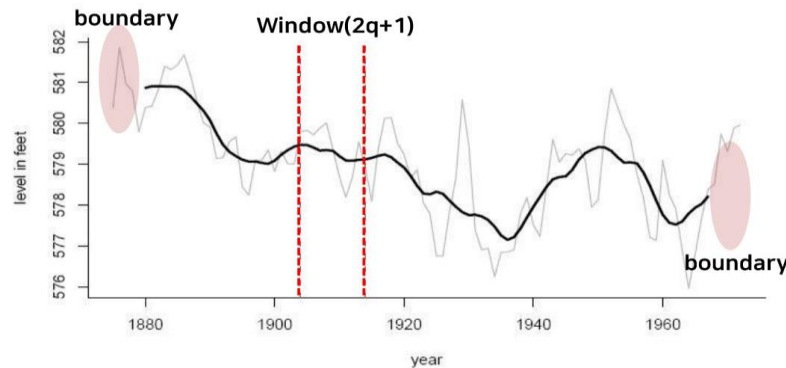


## 평균이 일정하지 않은 경우의 정상화 - ② 평활

a. 추세만 존재하는 경우 : 이동평균 평활법

Step 1) 길이가  $2q+1$ 인 구간의 평균 구하기

$$\begin{aligned} W_t &= \frac{1}{2q+1} \sum_{j=-q}^{j=q} (m_{t+j} + Y_{t+j}) \\ &= \frac{1}{2q+1} \sum_{j=-q}^q m_{t+j} + \frac{1}{2q+1} \sum_{j=-q}^q Y_{t+j} \end{aligned}$$



## 평균이 일정하지 않은 경우의 정상화 - ② 평활

a. 추세만 존재하는 경우 : 이동평균 평활법

Step 2) 추세 성분  $m_t$ 를 대입하여 구간의 평균  $W_t$ 를 근사적으로 추세  $m_t$ 와 같게 만들기

$$W_t = \frac{1}{2q+1} \sum_{j=-q}^q m_{t+j} + \frac{1}{2q+1} \sum_{j=-q}^q Y_{t+j} = m_t$$

$$\frac{1}{2q+1} \sum_{j=-q}^q Y_{t+j} \approx E(Y_t) = 0 \text{ (by WLLN)}$$

$$m_t = c_0 + c_1 t, E(Y_t) = 0$$

Step 3) 추세부분만 남은  $W_t$ 를  $X_t$ 에서 제거



평균이 일정하지 않은 경우의 정상화 - ② 평활

## 이동평균 평활법의 한계

a. 추세만 존재하는 경우 : 이동평균 평활법

Step 2) 추세 성분  $m_t$ 를 대입하여 구간의 평균  $W_t$ 를 근사적으로 추세  $m_t$ 와 같게 만들기

데이터의 맨 앞  $q$ 개와 맨 뒤  $q$ 개의 boundary 추정 불가

현실에서 미래 관측값 사용 불가

$$\frac{1}{2q+1} \sum_{j=-q}^{j=q} Y_{t+j} \approx E(Y_t) = 0 \text{ (by WLLN)}$$

$$m_t = c_0 + c_1 t, E(Y_t) = 0$$

과거 데이터만을 활용하는 **지수 평활법** 활용

Step 3) 추세부분만 남은  $W_t$ 를  $X_t$ 에서 제거

## 평균이 일정하지 않은 경우의 정상화 - ② 평활

a. 추세만 존재하는 경우 : 지수 평활법

### Step 1) 추세 추정

$$\hat{m}_1 = X_1$$

$$\hat{m}_2 = aX_2 + (1-a)\hat{m}_1 = aX_2 + (1-a)X_1$$

$$\hat{m}_3 = aX_3 + (1-a)\hat{m}_2 = aX_3 + a(1-a)X_2 + (1-a)^2X_1$$

$$\hat{m}_t = aX_t + (1-a)\hat{m}_{t-1} = \sum_{j=0}^{t-2} a(1-a)^j X_{t-j} + (1-a)^{t-1} X_1$$



과거의 관측치일수록  
가중치의 값이 지수적으로 감소

$a \in [0,1]$ , 과거 관측치에 대한 가중치


### Step 2) 추세 제거

## 평균이 일정하지 않은 경우의 정상화 - ② 평활

b. 계절성만 존재하는 경우 : Seasonal Smoothing

### Seasonal Smoothing

주기가  $d$ 인 시계열 자료에서 주기만큼의 데이터를 모두 겹친 후,  
겹친 값들의 평균으로 계절성을 추정하는 방법



## 평균이 일정하지 않은 경우의 정상화 - ② 평활

b. 계절성만 존재하는 경우 : Seasonal Smoothing

STEP 1) 계절성분( $\hat{S}_k$ ) 추정

$$\hat{S}_k = \frac{1}{m} (x_k + x_{k+d} + \cdots + x_{k+(m-1)d}) = \frac{1}{m} \sum_{j=0}^{m-1} x_{k+jd}$$

STEP 2) 추정된 계절성분을 다른 주기에 적용, 전체 계절성 추정

STEP 3) 계절성을 시계열 자료에서 제거




## 평균이 일정하지 않은 경우의 정상화 - ② 평활

c. 추세와 계절성 모두 존재하는 경우 : Classical Decomposition Algorithm

Step 1) MA filter를 사용해 추세 추정

$$\text{if } d = 2q \text{ (even),} \quad \hat{m}_t = \frac{0.5X_{t-q} + X_{t-q+1} + \cdots + X_{t+q-1} + 0.5X_{t+q}}{2q}$$


$$\text{if } d = 2q + 1 \text{ (odds),} \quad \hat{m}_t = \frac{X_{t-q} + X_{t-q+1} + \cdots + X_{t+q-1} + X_{t+q}}{2q + 1}$$




## 평균이 일정하지 않은 경우의 정상화 - ② 평활

c. 추세와 계절성 모두 존재하는 경우 : Classical Decomposition Algorithm

Step 2) 추세 제거 후,  
Seasonal Smoothing을 통해 계절성 추정



Step 3) 계절성 제거 후,  
OLS를 활용해 추세 재추정 후 제거




OLS 대신 Smoothing 사용 가능,  
일반적인 경우 OLS 사용


## 평균이 일정하지 않은 경우의 정상화 - ② 평활

c. 추세와 계절성 모두 존재하는 경우 : Classical Decomposition Algorithm

Step 2) 추세 제거 후,  
Seasonal Smoothing을 통해 계절성 추정



Step 3) 계절성 제거 후,  
OLS를 활용해 추세 재추정 후 제거



OLS 대신 Smoothing 사용 가능,  
일반적인 경우 OLS 사용

## 평균이 일정하지 않은 경우의 정상화 - ② 평활

c. 추세와 계절성 모두 존재하는 경우 : Classical Decomposition Algorithm

Step 2) 추세 제거 후,

Seasonal Smoothing을 통해 계절성 추정



잔여 추세가 존재 한다면  
[1]~[3] 과정 반복해 추세 제거

Step 3) 계절성 제거 후,

OLS를 활용해 추세 재추정 후 제거



OLS 대신 Smoothing 사용 가능,  
일반적인 경우 OLS 사용

## 평균이 일정하지 않은 경우의 정상화 - ③ 차분

차분 (Differencing)

이 '차이'를 이용하여 추세와 계절성을 제거



관측값들의 차이를 구하는 것



후향 연산자를 사용하여 차분을 진행

후향 연산자

$$BX_t = X_{t-1}$$

관측값을 한 시점 전으로  
돌려주는 역할을 하는 연산자

## 평균이 일정하지 않은 경우의 정상화 - ③ 차분

이 '차이'를 이용하여 추세와 계절성을 제거

차분 (Differencing)

관측값들의 차이를 구하는 것

⋮

후향 연산자를 사용하여 차분을 진행

1차 차분

$$\nabla X_t = X_t - X_{t-1} = (1 - B)X_t$$

후향 연산자

$$BX_{t-1} = X_{t-1}$$

관측값을 한 시점 전으로

돌려주는 역할을 하는 연산자

2차 차분

$$\nabla^2 X_t = \nabla(\nabla X_t) = \nabla(X_t - X_{t-1})$$

$$= X_t - 2X_{t-1} + X_{t-2}$$

$$= (1 - B)^2 X_t$$

## 평균이 일정하지 않은 경우의 정상화 - ③ 차분

a. 추세만 존재하는 경우 - 차분(Differencing)

$m_t = c_0 + c_1 t$  를 가정한 후 1차 차분 적용

$$\nabla m_t = (c_0 + c_1 t) - (c_0 + c_1(t-1)) = c_1$$

t에 영향을 받지 않는 상수

⋮

k차 차분하면 k차 추세가 제거됨

$$\nabla^k X_t = k! c_k + \nabla^k Y_t = \text{const}, + \text{error}$$

## 평균이 일정하지 않은 경우의 정상화 - ③ 차분

a. 추세만 존재하는 경우 - 차분(Differencing)



$$\nabla^k X_t = k! c_k + \nabla^k Y_t = \text{const}, + \text{error}$$

$$\nabla m_t = (c_0 + c_1 t) - (c_0 + c_1(t-1)) = c_1$$

차분을 통해 추세를 제거하는 방법은 직관적이지만,  
위 식과 같이 오차까지 차분되어 식이 복잡해질 수 있다는 단점!

k차 차분하면 k차 추세가 제거됨

$$\nabla^k X_t = k! c_k + \nabla^k Y_t = \text{const}, + \text{error}$$



## 평균이 일정하지 않은 경우의 정상화 - ③ 차분

### b. 계절성만 존재하는 경우 - Seasonal Differencing

계절성만 존재하는 경우 lag-d differencing을 통해 계절성을 제거함

$$\nabla_d X_t = (1 - B^d)X_t, \quad t = 1, \dots, n$$

⋮

$s_t = s_{t+d}$ 를 가정하고 lag-d 차분을 적용하면...

$$\nabla_d X_t = s_t - s_{t-d} + Y_t - Y_{t-d} = 0 + \text{error}$$



오차항만 남아 계절성이 제거됨!



평균이 일정하지 않은 경우의 정상화 - 차분



b. 계절성만 존재하는 경우 - Seasonal Differencing

## 차분의 표현법 차이

계절성만 존재하는 경우 lag-d differencing을 통해 계절성을 제거함

d차 차분

$$\nabla_d X_t = (1 - B^d)X_t, \quad t = 1, \dots, n$$

lag-d 차분

$$\nabla^d = (1 - B)^d$$

를 가정하고

lag-d 차분을 적용하면

$$\nabla_d = (1 - B^d)$$

$$\nabla_d X_t = s_t - s_{t-d} + Y_t - Y_{t-d} = 0 + \text{error}$$



오차항만 남아 계절성이 제거됨!

## 평균이 일정하지 않은 경우의 정상화 - ③ 차분

c. 추세와 계절성 모두 존재하는 경우 : Lag-d 차분 + p차 차분

### STEP 1) 계절차분

$$\nabla_d X_t = m_t - m_{t-d} + Y_t - Y_{t-d}$$



계절성은 사라지고 추세만 남게 됨

## 평균이 일정하지 않은 경우의 정상화 - ③ 차분

c. 추세와 계절성 모두 존재하는 경우 : Lag-d 차분 + p차 차분

STEP 2) 남아있는 추세 제거를 위한 차분 진행

$$\nabla_d = (1 - B^d) = (1 - B)(1 + B + \dots + B^{d-1})$$



계절 차분에  $(1 - B)$ 가 포함

→ (p-1)차 차분을 진행

## 평균이 일정하지 않은 경우의 정상화 - ③ 차분

c. 추세와 계절성 모두 존재하는 경우 : Lag-d 차분 + p차 차분

STEP 2) 남아있는 추세 제거를 위한 차분 진행

$$\nabla_d = (1 - B^d) = (1 - B)(1 + B + \dots + B^{d-1})$$




계절 차분에  $(1 - B)$ 가 포함

→ (p-1)차 차분을 진행

# 4

정상성 검정

## 정상성 검정



시계열 데이터에서 비정상 부분이 성공적으로 제거되었다면  
정상성을 만족하는 오차  $y_t$ 만이 데이터에 남아 있어야 함



- ① 자기공분산함수 (ACVF)
- ② 자기상관함수 (ACF)

를 이용하여 정상성 만족 여부를 확인

## 자기공분산함수(ACVF), 자기상관함수(ACF)

## 자기공분산함수(ACVF)

$$\gamma_X(h) = \text{Cov}(X_t, X_{t+h}) = E[(X_t - \mu)(X_{t+h} - \mu)]$$

## 자기상관함수(ACF)

$$\rho_X(h) = \frac{\gamma_X(h)}{\gamma_X(0)} = \text{Corr}(X_t, X_{t+h}) = \frac{\text{Cov}(X_t, X_{t+h})}{\sqrt{\text{var}(X_t)}\sqrt{\text{var}(X_{t+h})}}$$



## 자기공분산함수(ACVF), 자기상관함수(ACF)

### 자기공분산함수(ACVF)

$$\gamma_x(h) = \text{Cov}(X_t, X_{t+h}) = E[(X_t - \mu)(X_{t+h} - \mu)]$$



같은 결합 분포 내에서 시차를 가지는 변수들의 공분산을 구하는 식이므로

위 식을 통해  $\gamma_x(0) = \text{Var}(X_t)$ 라는 것을 알 수 있음

$$\rho_x(h) = \frac{\gamma_x(h)}{\gamma_x(0)} = \text{Corr}(X_t, X_{t+h}) = \frac{\text{Cov}(X_t, X_{t+h})}{\sqrt{\text{var}(X_t)}\sqrt{\text{var}(X_{t+h})}}$$

## 자기공분산함수(ACVF), 자기상관함수(ACF)

## 자기공분산함수(ACVF)

$$\gamma_x(h) = \text{Cov}(X_t, X_{t+h}) = E[(X_t - \mu)(X_{t+h} - \mu)]$$

시계열데이터에서 **샘플링**된 데이터의 정상성을 검정하기 위해서는  
**표본자기공분산함수(SACVF)와 표본자기상관함수(SACF)**를 사용함!

위 식을 통해  $\gamma_x(0) = \text{Var}(X_t)$ 라는 것을 알 수 있음

$$\rho_x(h) = \frac{\gamma_x(h)}{\gamma_x(0)} = \text{Corr}(X_t, X_{t+h}) = \frac{\text{Cov}(X_t, X_{t+h})}{\sqrt{\text{var}(X_t)}\sqrt{\text{var}(X_{t+h})}}$$

## 표본자기공분산함수(SACVF), 표본자기상관함수(SACF)

표본자기공분산함수(SACVF)

$$\hat{\gamma}_x(h) = \frac{1}{n} \sum_{j=1}^{n-h} (X_j - \bar{X})(X_{j+h} - \bar{X})$$

표본자기상관함수(SACF)

$$\hat{\rho}_x(h) = \frac{\hat{\gamma}_x(h)}{\hat{\gamma}_x(0)}, \quad \hat{\rho}(0) = 1$$

## 백색잡음 (White Noise)

## White Noise Process (백색잡음)

자기상관이 존재하지 않는 시계열 데이터

1. 시계열  $\{X_t\}$ 의 평균이 0, 분산이  $\sigma^2 < \infty$ 인 경우
2. 시계열  $\{X_t\}$ 에 상관관계가 존재하지 않는 경우



시계열  $\{X_t\}$ 는  $\{X_t\} \sim WN(0, \sigma^2)$ 로 표현되는  
백색잡음이라고 볼 수 있음

## 백색잡음 (White Noise)

White Noise Process (백색잡음)



자기상관이 존재하지 않는 시계열 데이터

우리가 일반적으로 사용하는  $IID(0, \sigma^2)$ 는 백색잡음이지만,

반대로 **백색잡음은  $IID(0, \sigma^2)$ 가 아닐 수 있음**에 유의 !!

1. 시계열  $\{X_t\}$ 의 평균이 0, 분산이  $\sigma^2 < \infty$ 인 경우

2. 시계열  $\{X_t\}$ 에 상관관계가 존재하지 않는 경우

⋮

⋮

IID와 비교하여 **독립성 조건이 완화**된 것이 백색잡음!

$$E[X_t] = 0, \text{Var}[X_t] = \sigma^2$$

$$E[X_t X_s] = 0, \text{for } t \neq s$$

시계열  $\{X_t\}$ 는  $\{X_t\} \sim WN(0, \sigma^2)$ 로 표현되는

백색잡음이라고 볼 수 있음

## 백색잡음 (White Noise) 검정

비정상 시계열 데이터로부터 추세  $m_t$ , 계절성  $s_t$ 를 성공적으로 제거했다면,  
남아있는 오차항은 **WN조건** 혹은 IID조건을 만족함

WN조건을 만족한다는 것은  $\{X_t\} \sim WN(0, \sigma^2)$  와 동치



따라서  $\gamma_x(0) = \text{Var}(X_t) = \sigma^2$  이므로,  $\sigma^2$ 만을 추정하여  
오차항이 WN조건을 만족하는지를 검정!

## 백색잡음 (White Noise) 검정

자기상관 검정

정규성 검정

정상성 검정



## 백색잡음 (White Noise) 검정 - ① 자기상관 검정

오차항이 백색잡음을 따른다면  $\hat{\rho} \approx N(0, \frac{1}{n})$  라는 점에 기반하여 아래 가설을 검정

$$H0 : \rho(h) = 0$$

$$H1 : \rho(h) \neq 0$$

⋮

$|\hat{\rho}(h)| < \frac{1.96}{\sqrt{n}}$  라면  $H0$ 를 기각할 수 없다.


이는 곧 오차항에 자기상관성이 없음을 의미한다.





## 백색잡음 (White Noise) 검정 - ① 자기상관 검정

ACF plot



ACF plot의 X축은 시차, y축은 acf를 의미한다.

파란색 영역은 자기상관 검정의 신뢰구간이다.

## 백색잡음 (White Noise) 검정 - ① 자기상관 검정



ACF plot의 X축은 시차, y축은 acf를 의미한다.

파란색 영역은 자기상관 검정의 신뢰구간이다.

## 백색잡음 (White Noise) 검정 - ② 정규성 검정

 $H_0$  : 정규성이 존재한다. $H_1$  : 정규성이 존재하지 않는다.

QQ Plot

시각적으로 정규성을 확인할 수 있는 검정

KS Test

표본과 모집단의 누적확률분포가 얼마나 유사한지 비교하는 검정

Jarque-Bera Test

왜도와 첨도를 이용한 검정

## 백색잡음 (White Noise) 검정 - ③ 정상성 검정

검정	H0
Kpss Test	정상 시계열이다.
ADF Test	정상 시계열이 아니다.
PP Test	



이분산이 있는 경우에도 사용 가능한 검정 방법

# 다음 주 예고

---

1. 모형 식별
2. 선형과정
3. AR 모형
4. MA 모형
5. ARMA 모형
6. 적합 절차

# 감사합니다

---

